

# Sarcasm Detection con SLM & Multitask Learning

- Domenico De Marchis
- Francesco Fontanesi

DEEP LEARNING

GENNAIO 2026





# Generalità

## Problema Chiave

Il sarcasmo richiede contesto e informazioni spesso non disponibili: Sarcasmo Implicito e Intended

## Ipotesi

Il Fine - Tuning di modelli più piccoli può permettere di superare LLM in zero - shot

## Modelli Analizzati

- **ModernBERT**: encoder-only, evoluzione di BERT
- **Phi-3**: decoder-only SLM open-source
- **Llama-3.3-70b & Kimi-K2**: LLM benchmark via API Groq



## Pre - Concetti



### ModernBERT

- più contesto, RoPE, Alternating Attention, Unpadding e GeGLU
- la classificazione del testo sfrutta sempre  $[CLS]$



### Phi3



- più contesto, RoPE, RMSNorm, SwiGLU, Alternating BlockSparse Attention
- la classificazione del next token  $T$  sfrutta l'embedding del token  $T - 1$



### LoRA

- si sfrutta una correzione di basso rango:
$$W' = W + \Delta W, \Delta W = BA$$
- **Idea:** pochi parametri per adattare l'espressività

## Baseline e Risultati - 1





OBIETTIVO

## Baseline e Risultati - 2

**98%**

Recall Llama-3.3

Trova quasi tutto il sarcasmo

**21%**

Precision Llama

Moltissimi falsi positivi

**733**

Falsi Positivi

Su 1200 esempi non sarcastici

**Comportamento Zero-Shot: I LLM tendono a sovrastimare massivamente la classe "Sarcastic"**

# iSarcasmEval

1

## Sbilanciamento 1:3

Rapporto significativo tra classe sarcastica e non sarcastica, principalmente tweets

2

## Scelta Deliberata

Nessuna integrazione Reddit per evitare vocabulary mismatch (slang, stile diverso)

3

## Rephrasing Unico

Versioni parafrasate non sarcastiche per esempi sarcastici - base per approccio multitask

# La Scelta

## 1 Data Augmentation

- fatto dagli autori stessi
- permette stime più solide
- Vocabulary Mismatch Problem

## 2 Impostazione del Problema

- usare i dati che abbiamo
- costruire task ausiliari
- peso maggiore ai positives

Per gli obiettivi di un progetto come questo, abbiamo esplorato la seconda alternativa

# Strategie di Training



## Positive Weight

Peso maggiore alla loss su record positivi (rapporto 1:3)



## Multitask Learning

Diversi Task ausiliari: tutti sfruttano il rephrasing del dataset



## Loss Combinata

Combinazione lineare a peso configurabile:  $L = \lambda_A L_A + \lambda_B L_B$

# Auxiliary Tasks

La filosofia adottata è sempre quella di un **Hard Parameter Sharing**

## 1 Main Task

Dato il Testo, prevedere se sia Sarcastic / Non Sarcastic

## 2 Auxiliary Task A

Data la coppia (*Testo, Rephrase*), identificare quale dei due sia la versione Sarcastic

## 3 Auxiliary Task B

Data la coppia (*Testo, Rephrase*), spingere gli score prodotti ad essere distanti di almeno una quantità  $m$

## 4 Auxiliary Task C

Dato il Testo, generare la sua versione Rephrased (solo per Phi-3)

## Auxiliary Losses

La base è sempre una **Cross Entropy**:  $L(s, y) = -\log(p(y))$  o **Binary**  $L(s, y) = [-\alpha \cdot y \cdot \log(\sigma(s)) + (1 - y) \cdot \log(1 - \sigma(s))]$

### Main Task & Task A

- Funzionamento classico
- Score  $s$  alto positivo per  $y = 1$ , viceversa per  $y = 0$ .

### Task B


- Praticamente una **Contrastive Loss**
- Massimizza distanza tra gli score:

$$L(s_a, s_b) = \max(0, m - (s_a - s_b))$$

### Task C


- **Generative Loss**
- CE rispetto la distribuzione del target:  
$$\mathcal{L} = \frac{\sum_{i,t} w_i \cdot \mathbf{1}_{\text{active}}(i,t) \cdot \text{CE}(\hat{y}_{i,t}, y_{i,t})}{\sum_{i,t} w_i \cdot \mathbf{1}_{\text{active}}(i,t)}$$

# Risultati



ModernBERT supera LLama, ma tra tutte le configurazioni provate Kimi rimane un tetto

# Ablazione



Model	F1 - Score	Precision	Recall	Threshold	Auxiliary Task
modernbert_o1	0.25	0.14	0.96	0.5	Task A
modernbert_o2_only_task_main	0.24	0.17	0.43	0.75	None
modernbert_o2_second	0.36	0.26	0.55	0.75	Task B
modernbert_o2_ablation_weight	0.27	0.28	0.25	0.75	Task B
modernbert_o2_ablation_all	0.08	0.24	0.05	0.5	None

Nota: la Tabella riporta Performance sulla classe 'Sarcastic'

# Threshold Tuning

- Il Validation Set è piccolo e rumoroso: non possiamo ricavare stime significative, usiamo  $t = 0.5$

## 1 Dataset Sbilanciato


Il parametro *pos\_weight* permette di bilanciare la distribuzione del gradiente

## 2 Soglia Teorica

Con  $pos\_weight = 3.0$ , soglia neutrale si sposta a 0.75

## 3 Calibrazione

$$p_{real} = \frac{p_{weighted}}{p_{weighted} + (1 - p_{weighted})W}$$




# ModernBERT: Conclusioni

1

## Risultato

Prestazioni discrete, performa similmente ad un 70B in zero - shot ed i parametri allenati sono irrisori




**Best Score F1**

Margin Loss Task B + Positive Weighting

2

## Problematiche

Il Task è molto complesso, difatti gli autori raggiungono prestazioni migliori con ensemble



**Parametri Trained**

LoRA su ModernBERT totale

# Decoder-Only: Approccio Generativo

01

## Predizione Generativa

Modello genera etichetta esplicita  
(A=sarcastico, B=non sarcastico)

02

## Analisi Logit

Valutazione di confidenza, soglia  $\tau$  su  
 $\Delta = \log(p(A)) - \log(p(B))$

03

## Task C: Rewriting

Il modello impara direttamente il  
Rephrasing... puoi farlo qui!

 Con ModernBERT alleniamo di fatto una NUOVA TESTA, non con Phi-3!

# Ablazione

## WEIGHTS

Interessante caso: la configurazione migliore è con un  $pos\_weight = 1$ , un ulteriore peso ai positivi causa drift

## TASK C

Il Task C di Rephrasing si dimostra importante per un Gain prestazionale, ma solo **con opportuno peso**

Model	F1 - Score	Precision	Recall	Threshold	Setup
phi_ablation_c	0.50	0.37	0.76	1.10	No Task C
phi_o1	0.58	0.61	0.56	0.00	No Pos. Weights
phi_o2	0.52	0.42	0.69	1.10	Task C + Pos. Weights
phi_eq_weight	0.27	0.28	0.25	1.10	Task C + Pos. Weights

**Nota: ci sono meno configurazioni che con ModernBERT, puramente per bottleneck hardware**

## Domain Weight Shift

(?) Perché il peso positivo causa drift?

- In **ModernBERT** l'ultimo layer (head) è **inizializzato casualmente** e deve imparare **da zero** il decision boundary, qui la LM Head è fissa
- in BERT pos\_weight serve a “trovare” la minoritaria; in Phi-3 può **creare confusione** perché interferisce con una **distribuzione prior già presente**

Non c'è una spiegazione esatta, quella fornita è (per noi) la più plausibile

# Conclusioni: Phi-3 Vince 🏆

**58%**

F1-Score Phi-3

Multitask fine-tuned (best)

**60%**

Precision

+35 punti vs Kimi

**0.23%**


Parametri Trained

9M su 3.8B totali con LoRA

**60%**

Best F1 iSarcasmEval

Ensemble di BERT - based



È possibile superare le prestazioni di LLM con SLM Fine - Tuned per Sarcasm Detection?  
Si e di molto!

# Reddit

## Obiettivo

Far vedere perché i LLM sono spesso preferibili ed il problema del Fine Tuning: zero - shot e domain shift

## Reddit

Lo stile è lo stesso dei Tweet, cambia il vocabolario e le prestazioni degradano rispetto ad iSarcasmEval

Model	F1 - Score	Precision	Recall	Setup
phi_3	0.51	<b>0.66</b>	0.42	Base
phi_3	0.55	0.62	0.49	Fine Tuned iSarcasmEval
modernbert	0.43	0.62	0.33	Fine Tuned iSarcasmEval
kimi_k2 🏆	<b>0.680</b>	0.58	0.80	Zero - Shot
llama_70b 🏆	<b>0.684</b>	0.55	0.89	Zero - Shot

Il Fine - Tuning è Domain Specific, i benefici vengono mitigati da un domain shift